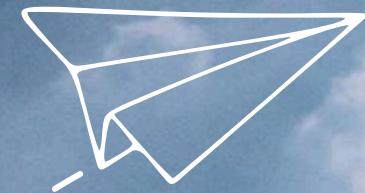


CONCURRENT FLIGHTS PREDICTION BASED ON OPERATIONAL AND WEATHER DATA

kelompok 9

Guided by

Mr. EKO SETYO PURWANTO, S.Pd., M.Kom.



NAMA ANGGOTA

**NICHOLAS
SINCLAIR
ALFIANTO
2702208581**

**PUTRI MAHARANI
SETIAWAN
2702375866**

**NATASHA DIAN
MAHARDITA
2702320210**

**LAVINIA
NATANIELA
NOVYANDI
2702331763**

**PAZELLA MUTIA
REFLIN
2702343523**

**SYAUQINA
ZHAFIRAH NUR
FAKHRANA
2702360750**

**VANESSA NAYLA
PUTRI
2702235084**





DAFTAR ISI

- 1. Latar Belakang
- 2. Data
- 3. Atribut
- 4. Data Cleaning
- 5. Data Preprocessing
- 6. Visualisasi
- 7. Hasil
- 8. Kesimpulan

LATAR BELAKANG

Manajemen lalu lintas udara yang efektif membutuhkan prediksi yang akurat terhadap jumlah penerbangan yang terjadi bersamaan (concurrent flights) di setiap waktu tertentu.

Kelebihan kapasitas tanpa perencanaan dapat menyebabkan keterlambatan, pemborosan biaya, dan penurunan layanan.

Dengan memanfaatkan 15 atribut utama dari 26 atribut seperti waktu penerbangan, jarak tempuh, karakteristik pesawat, hingga kondisi cuaca, kami mengembangkan model prediksi menggunakan XGBoost dan Random Forest untuk mendukung optimalisasi operasional bandara dan maskapai.

Analisis data berbasis machine learning ini diharapkan meningkatkan efisiensi, keselamatan, dan pengalaman pelanggan secara keseluruhan.

DATA

# MONTH Month	# DAY_OF_WEEK Day of Week	# DEP_DEL15 TARGET Binary of a departure delay over 15 minutes (1 is yes)	▲ DEP_TIME_BLK Distance group to be flown by departing aircraft	# DISTANCE_GROUP Distance group to be flown by departing aircraft	# SEGMENT_NUMBER The segment that this tail number is on for the day	# CONCURRENT_FLIG... Concurrent flights leaving from the airport in the same departure block
# NUMBER_OF_SEATS Number of seats on the aircraft	▲ CARRIER_NAME Carrier	# AIRPORT_FLIGHTS_... Avg Airport Flights per Month	# AIRLINE_FLIGHTS_M... Avg Airline Flights per Month	# AIRLINE_AIRPORT_F... Avg Flights per month for Airline AND Airport	# AVG_MONTHLY_PA... Avg Passengers for the departing airport for the month	# AVG_MONTHLY_PA... Avg Passengers for airline for month
# FLT_ATTENDANTS_... Flight attendants per passenger for airline	# GROUND_SERV_PER... Ground service employees (service desk) per passenger for airline	# PLANE_AGE Age of departing aircraft	▲ DEPARTING_AIRPORT Departing Airport	A LATITUDE Latitude of departing airport	A LONGITUDE Longitude of departing airport	▲ PREVIOUS_AIRPORT Previous airport that aircraft departed from
# PRCP Inches of precipitation for day	# SNOW Inches of snowfall for day	# SNWD Inches of snow on ground for day	# TMAX Max temperature for day	# AWND Max wind speed for day		

Sumber Data : <https://www.kaggle.com/datasets/threnjen/2019-airline-delays-and-cancellations>

PEMILIHAN ATRIBUT

Atribut dipilih untuk merepresentasikan faktor waktu, operasional penerbangan, serta karakteristik maskapai dan pesawat yang berpengaruh terhadap jumlah penerbangan bersamaan (concurrent flights).

- Waktu (MONTH, DAY_OF_WEEK, DEP_TIME_BLK): Menangkap pola musiman dan harian penerbangan.
- Kinerja Penerbangan (DEP_DEL15, DISTANCE_GROUP, SEGMENT_NUMBER): Menggambarkan potensi keterlambatan dan kompleksitas rute.
- Kapasitas (NUMBER_OF_SEATS): Mempengaruhi trafik udara.
- Karakteristik Maskapai (CARRIER_NAME, AIRLINE_FLIGHTS_MONTH, AIRLINE_AIRPORT_FLIGHTS_MONTH): Menunjukkan perbedaan frekuensi antar maskapai.
- Aktivitas Bandara (AIRPORT_FLIGHTS_MONTH): Mewakili tingkat kepadatan di bandara.
- Rasio Layanan (FLT_ATTENDANTS_PER_PASS, GROUND_SERV_PER_PASS): Mempengaruhi kecepatan operasional.
- Usia Pesawat (PLANE_AGE): Berkaitan dengan ketepatan operasional.
- CONCURRENT_FLIGHTS: Target variabel untuk prediksi.

DATA CLEANING

1. Memuat Data

Kita mulai dengan memuat dataset yang berisi data tentang penerbangan, bandara, maskapai, dan cuaca.

2. Menghapus Kolom yang Tidak Penting

Beberapa kolom yang tidak terlalu penting untuk prediksi kita dihapus, seperti:

- Nama bandara, maskapai, dan data geografis (koordinat lokasi bandara).
- Informasi cuaca yang bisa mengganggu prediksi.
- Data jumlah penumpang di bandara yang sudah ada di kolom lain.

3. Mengatasi Data yang Hilang

Data yang memiliki nilai kosong (missing) kita hapus supaya model tidak bingung saat dilatih.

DATA PREPROCESSING

4. Menambah Kategori Waktu Keberangkatan

Kolom DEP_TIME_BLK yang berisi jam penerbangan kita bagi menjadi kategori berdasarkan waktu:

- Subuh, Pagi, Siang, Sore, Malam

Lalu, kategori ini diubah menjadi format yang bisa diproses komputer (one-hot encoding).

5. Menentukan Fitur dan Target

- Fitur (X): Kolom-kolom yang digunakan untuk memprediksi (seperti jarak penerbangan, jumlah kursi, dan lainnya).
- Target (y): Kolom yang ingin kita prediksi, yaitu jumlah penerbangan yang bersamaan (CONCURRENT_FLIGHTS).

6. Membagi Data untuk Training dan Testing

Data dibagi menjadi dua bagian:

- 70% untuk melatih model (training).
- 30% untuk menguji model setelah dilatih (testing).

DATA CLEANING & PREPROCESSING

MONTH	DAY_OF_WEEK	DEP_DEL15	DISTANCE_GROUP	SEGMENT_NUMBER	CONCURRENT_FLIGHTS	NUMBER_OF_SEATS	AIRPORT_FLIGHTS_MONTH
0	1	7	0	2	1	25	143
1	1	7	0	7	1	29	191
2	1	7	0	7	1	27	199
3	1	7	0	9	1	27	180
4	1	7	0	7	1	10	182
...
6489057	12	7	0	1	11	3	123
6489058	12	7	0	1	11	2	123
6489059	12	7	0	1	11	2	123
6489060	12	7	0	1	12	3	123
6489061	12	7	1	1	12	3	123

AIRLINE_FLIGHTS_MONTH	AIRLINE_AIRPORT_FLIGHTS_MONTH	AVG_MONTHLY_PASS_AIRLINE	FLT_ATTENDANTS_PER_PASS	GROUND_SERV_PER_PASS
107363	5873	13382999	0.000062	0.000099
73508	1174	12460183	0.000144	0.000149
73508	1174	12460183	0.000144	0.000149
73508	1174	12460183	0.000144	0.000149
15023	1257	2688839	0.000009	0.000125
...
7268	757	905990	0.000120	0.000198
7268	757	905990	0.000120	0.000198
7268	757	905990	0.000120	0.000198
7268	757	905990	0.000120	0.000198
7268	757	905990	0.000120	0.000198

DATA CLEANING & PREPROCESSING

PLANE_AGE	TMAX	DEP_TIME_Malam	DEP_TIME_Pagi	DEP_TIME_Siang	DEP_TIME_Sore	DEP_TIME_Subuh
8	65.0	0	1	0	0	0
3	65.0	0	1	0	0	0
18	65.0	0	1	0	0	0
2	65.0	0	1	0	0	0
1	65.0	0	0	0	0	1
...
18	84.0	1	0	0	0	0
16	84.0	0	0	0	1	0
18	84.0	0	0	0	1	0
18	84.0	0	0	0	1	0
15	84.0	0	0	0	1	0



XGBOOST

VS

RANDOM FOREST

MODEL YANG DIGUNAKAN

1.XGBoost

XGBoost (Extreme Gradient Boosting) adalah algoritma machine learning decision tree yang menggunakan teknik gradient boosting untuk membuat prediksi yang lebih akurat

- Cocok untuk dataset sedang ke besar (6 juta baris) dan fitur numerik (hasil one-hot).
- Cepat melatih model dengan paralel processing.
- Kuat menangani data kompleks dan outlier.
- Punya regularisasi untuk menghindari overfitting saat prediksi concurrent flights.

TRAINING DAN TESTING

Training model awal menggunakan XGBRegressor

```
# Define features and target
X, y = df.drop('CONCURRENT_FLIGHTS', axis=1), df.CONCURRENT_FLIGHTS

# Split data
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

# Train XGBoost Model
xgb_reg = xgb.XGBRegressor(
    n_estimators=100,
    learning_rate=0.1,
    max_depth=6,
    subsample=0.8,
    colsample_bytree=0.8,
    random_state=42,
    n_jobs=-1
)

xgb_reg.fit(X_train, y_train)

# Predict
y_pred_xgb = xgb_reg.predict(X_test)
```

```
# Evaluate Performance
r2_train_xgb = xgb_reg.score(X_train, y_train)
r2_test_xgb = xgb_reg.score(X_test, y_test)

print(f"Akurasi model pada data training: {r2_train_xgb * 100:.2f}%")
print(f"Akurasi model pada data testing: {r2_test_xgb * 100:.2f}%")

mae_xgb = mean_absolute_error(y_test, y_pred_xgb)
rmse_xgb = math.sqrt(mean_squared_error(y_test, y_pred_xgb))

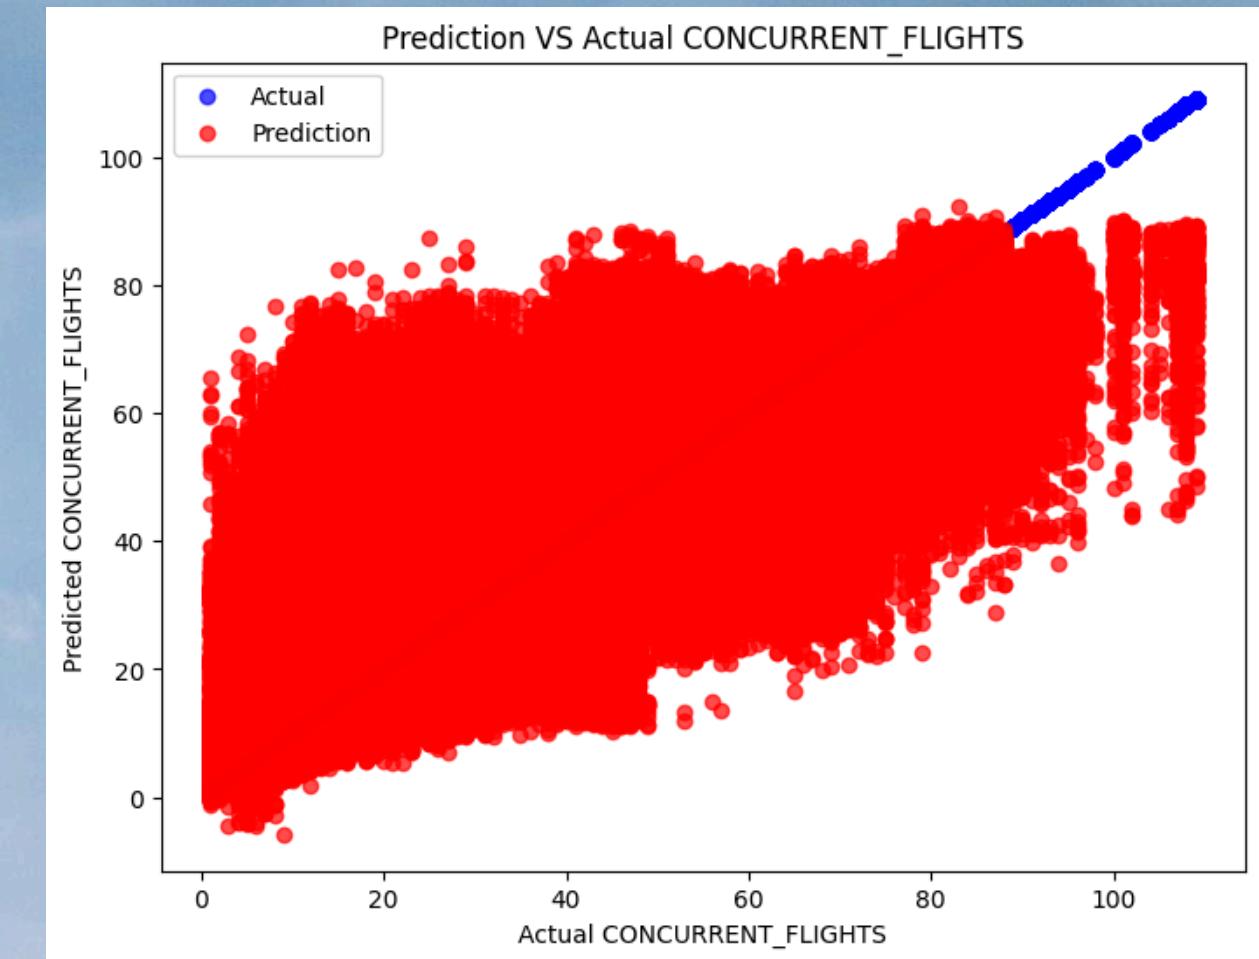
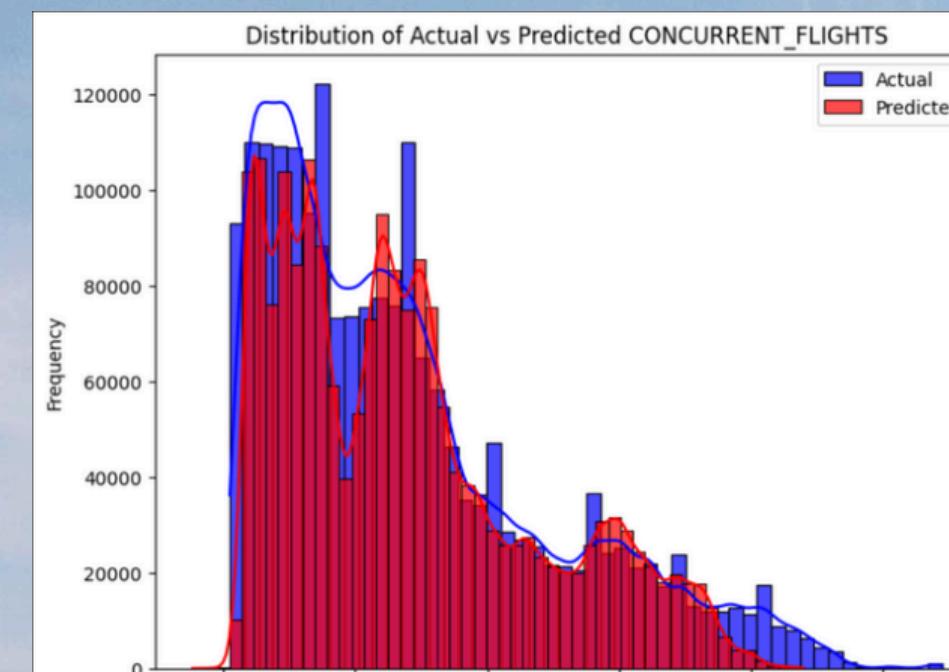
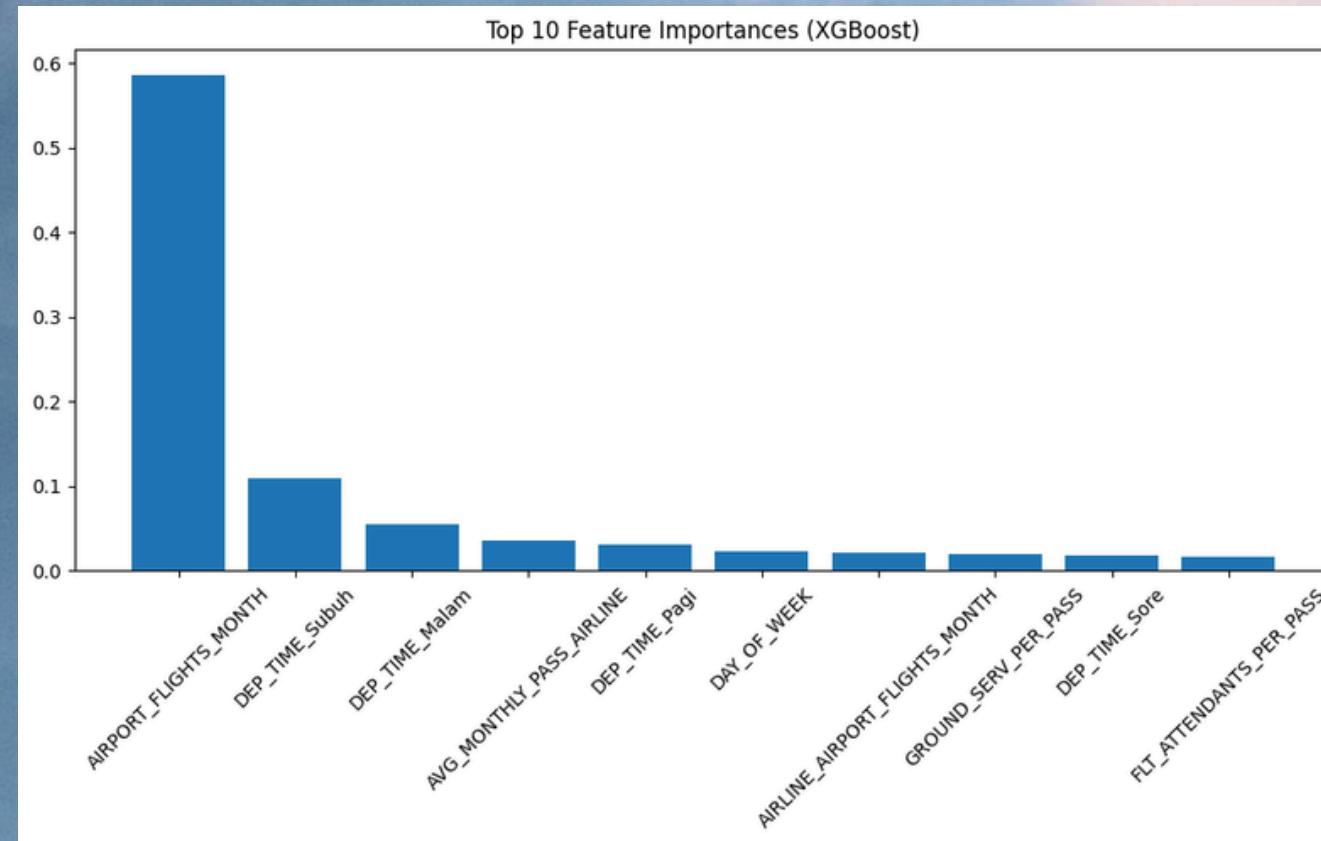
print(f"Rata-rata kesalahan prediksi (MAE): {mae_xgb:.2f}")
print(f"Rata-rata kesalahan terbesar (RMSE): {rmse_xgb:.2f}")
```

✓ 2.2s

```
Akurasi model pada data training: 81.84%
Akurasi model pada data testing: 81.86%
Rata-rata kesalahan prediksi (MAE): 6.17
Rata-rata kesalahan terbesar (RMSE): 9.16
```

TRAINING DAN TESTING

Actual dan predict concurrent flight



HYPERPARAMETER TUNING

Model di tuning menggunakan XGBRegressor

```
# Sample a smaller dataset for tuning |  
X_sample, _, y_sample, _ = train_test_split(X, y, train_size=2000000, random_state=42)
```

Memakai sample data agar proses tuning berjalan lebih cepat

```
Step 1 Best Params: {'max_depth': 11, 'min_child_weight': 1}  
Step 2 Best Params: {'colsample_bytree': 1.0, 'subsample': 0.9}  
Step 3 Best Params: {'learning_rate': 0.05, 'n_estimators': 700}  
Step 4 Best Params: {'gamma': 0}
```

```
# Parameter space untuk RandomizedSearchCV  
xgb_param = {  
    'n_estimators': [100, 300, 500],  
    'max_depth': [3, 5, 7, 9],  
    'learning_rate': [0.01, 0.05, 0.1],  
    'subsample': [0.6, 0.8, 1.0],  
    'colsample_bytree': [0.6, 0.8, 1.0],  
    'gamma': [0, 0.1, 0.3]  
}
```

Didapatkan hasil parameter sebagai berikut

FINAL MODEL PERFORMANCE

Akurasi model pada data training: 90.68%

Akurasi model pada data testing: 86.73%

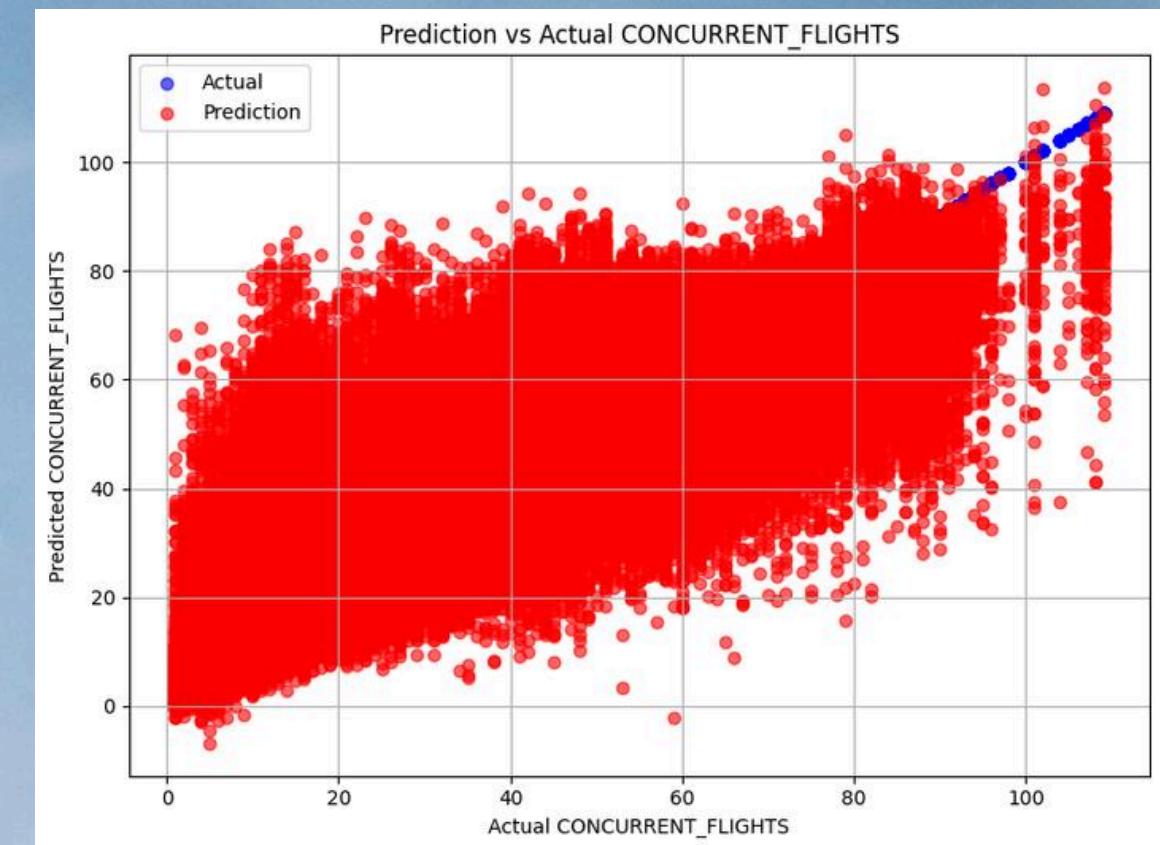
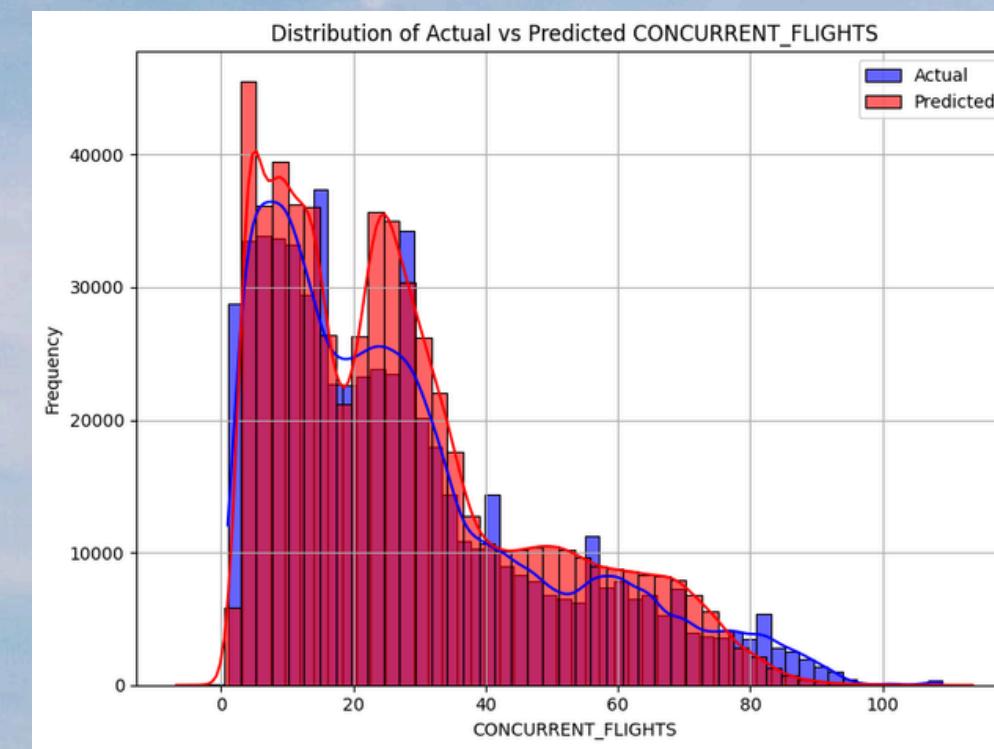
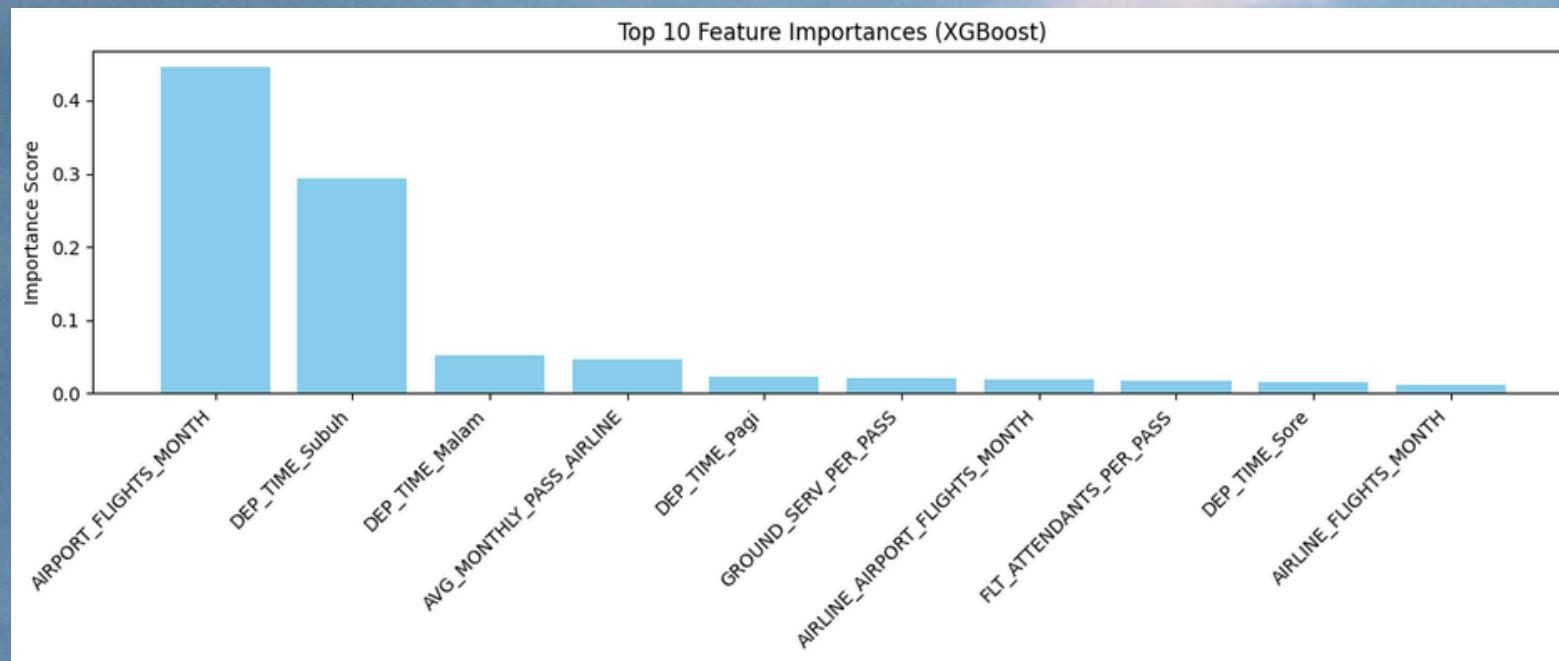
Rata-rata kesalahan prediksi (MAE): 5.02

Rata-rata kesalahan terbesar (RMSE): 7.84

Model di tuning menggunakan XGBRegressor untuk meningkatkan akurasi model agar tidak terjadi overfitting (model machine learning terlalu kompleks sehingga "menghafal" pola dan noise pada data latih (training data), tetapi gagal melakukan generalisasi dengan baik pada data baru atau data uji (testing data).

TRAINING DAN TESTING

Actual dan predict concurrent flight setelah dilakukan tuning



MODEL YANG DIGUNAKAN

2. Random forest

Random Forest adalah ensemble learning method yang menggabungkan banyak pohon keputusan (decision trees) untuk meningkatkan akurasi prediksi dan mengurangi overfitting.

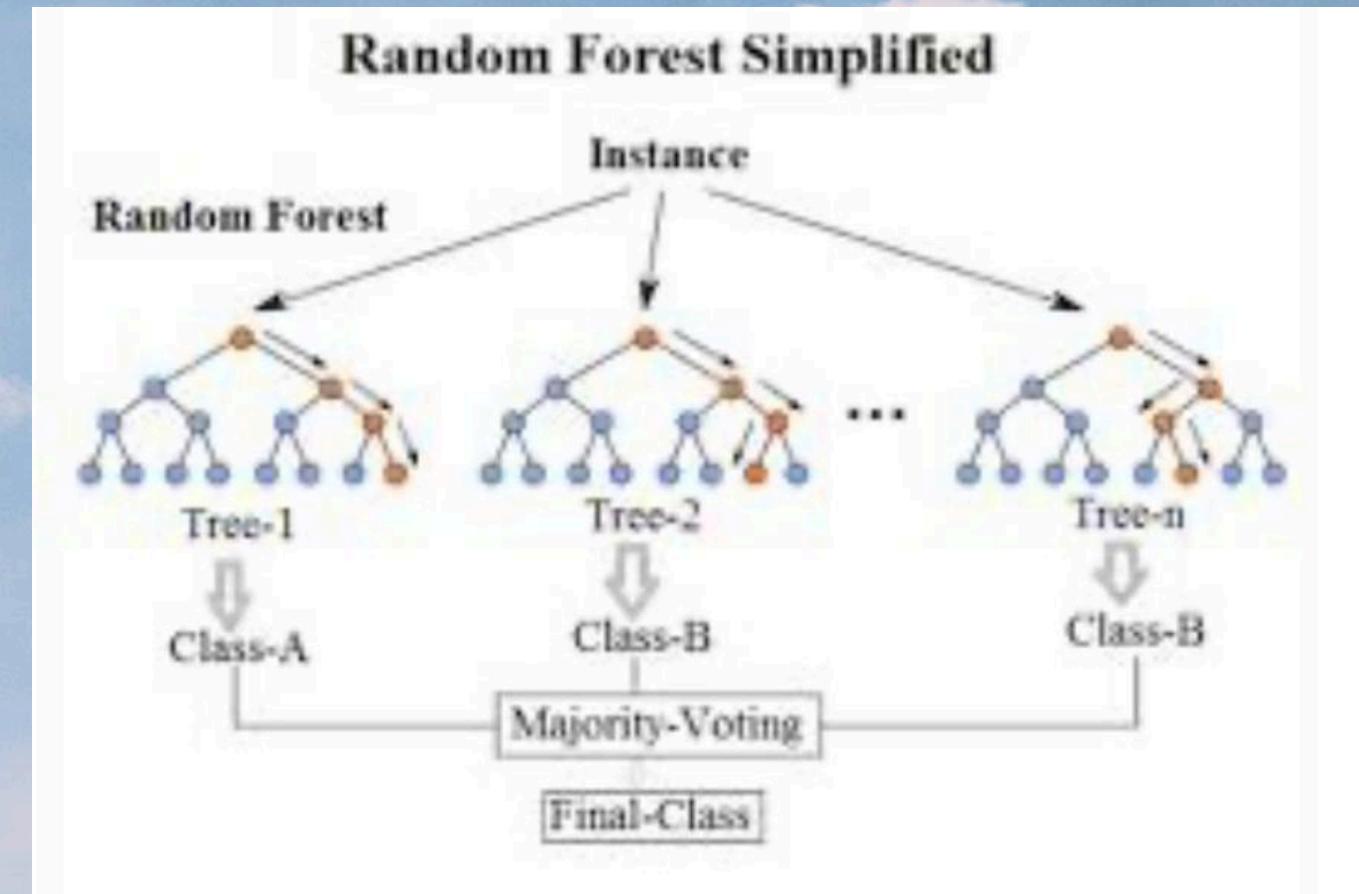
bootstrap
aggregating
atau bagging.



Decision tree
[splitting]



Voting decisions



TRAINING & TESTING

Training dan Testing awal Random Forest

```
# Train Regression Model with Optimized Hyperparameters
reg = RandomForestRegressor(
    n_estimators=100,
    max_depth=6,
    min_samples_split=10,
    min_samples_leaf=5,
    n_jobs=-1,
    random_state=42
)
reg.fit(X_train, y_train)
```

```
# Predict
y_pred = reg.predict(X_test)
```

```
# Evaluate Performance in Simple Terms
r2_train = reg.score(X_train, y_train)
r2_test = reg.score(X_test, y_test)

print(f"Akurasi model pada data training: {r2_train * 100:.2f}%")
print(f"Akurasi model pada data testing: {r2_test * 100:.2f}%")

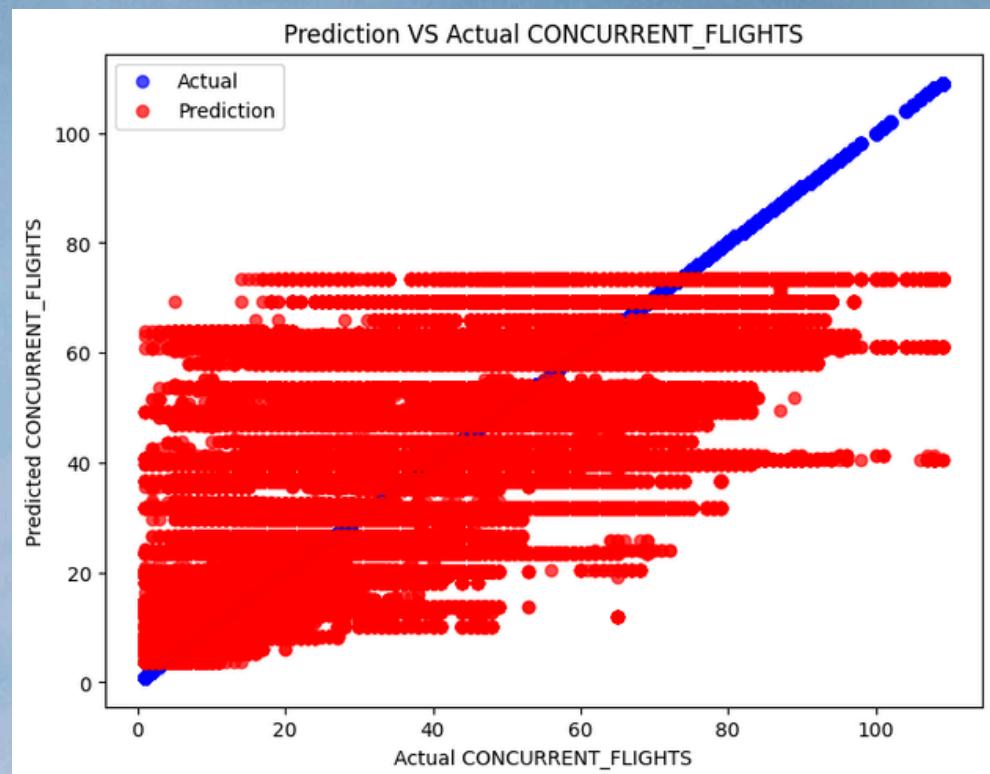
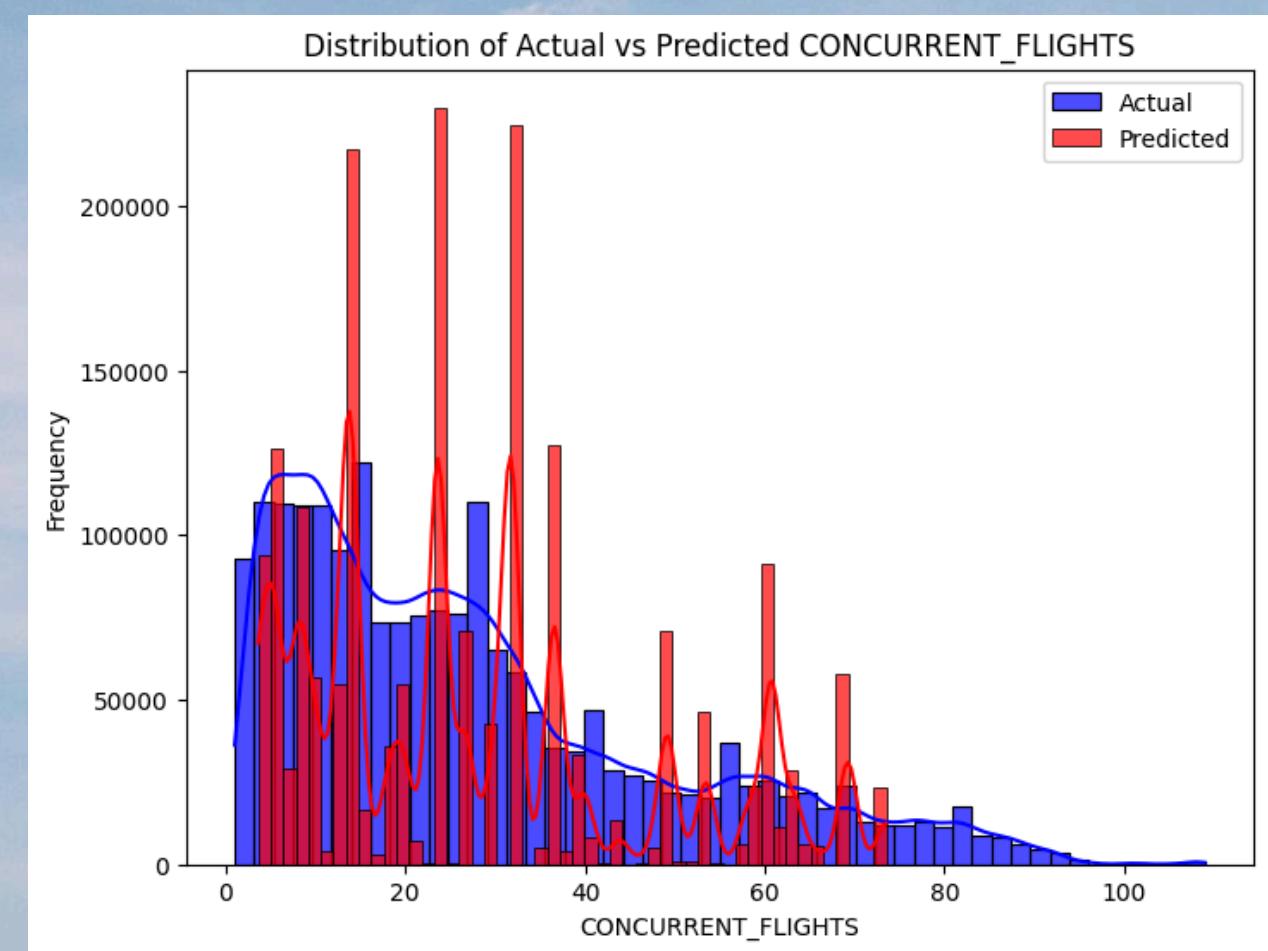
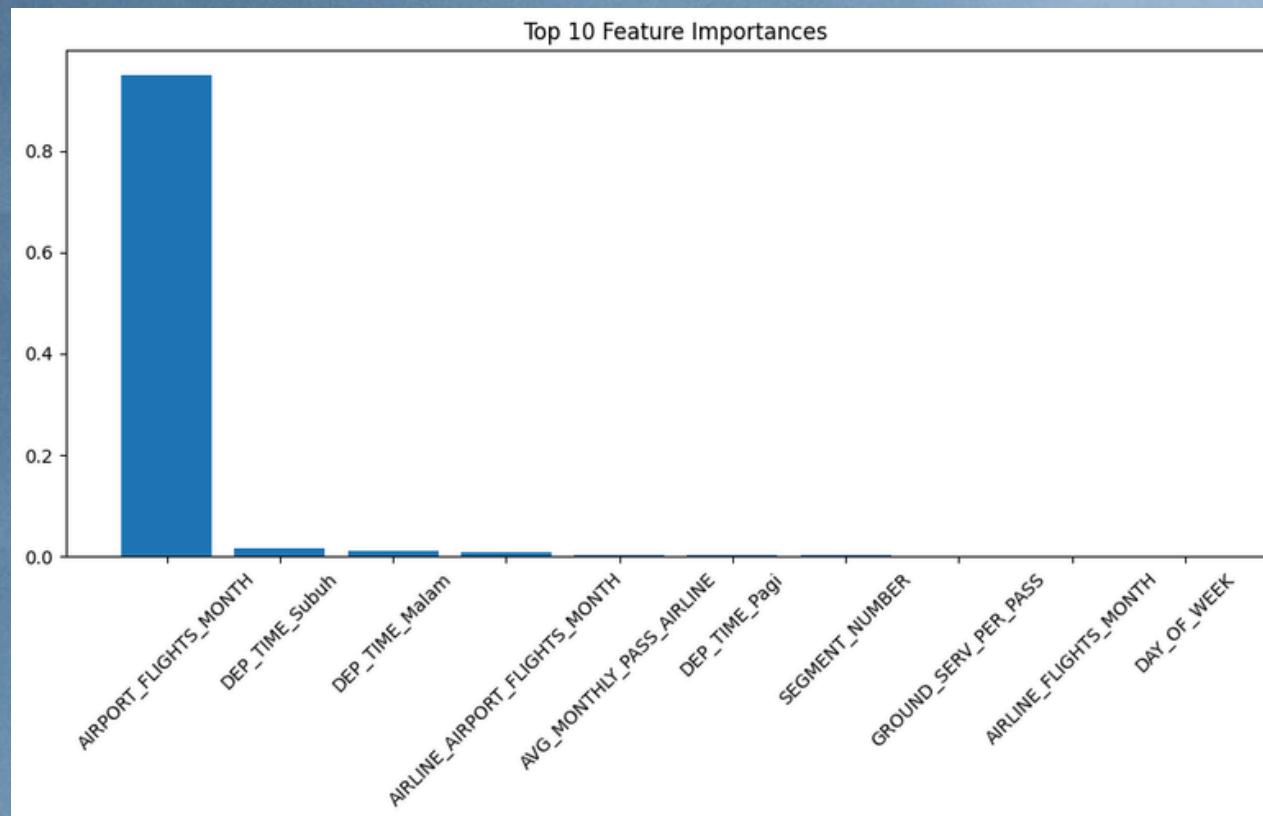
mae = mean_absolute_error(y_test, y_pred)
rmse = math.sqrt(mean_squared_error(y_test, y_pred))

print(f"Rata-rata kesalahan prediksi (MAE): {mae:.2f}")
print(f"Rata-rata kesalahan terbesar (RMSE): {rmse:.2f}")
```

Akurasi model pada data training: 76.72%
Akurasi model pada data testing: 76.74%
Rata-rata kesalahan prediksi (MAE): 7.09
Rata-rata kesalahan terbesar (RMSE): 10.38

TRAINING & TESTING

Training dan Testing awal Random Forest



HYPERPARAMETER TUNING

Model di tuning menggunakan Random forest

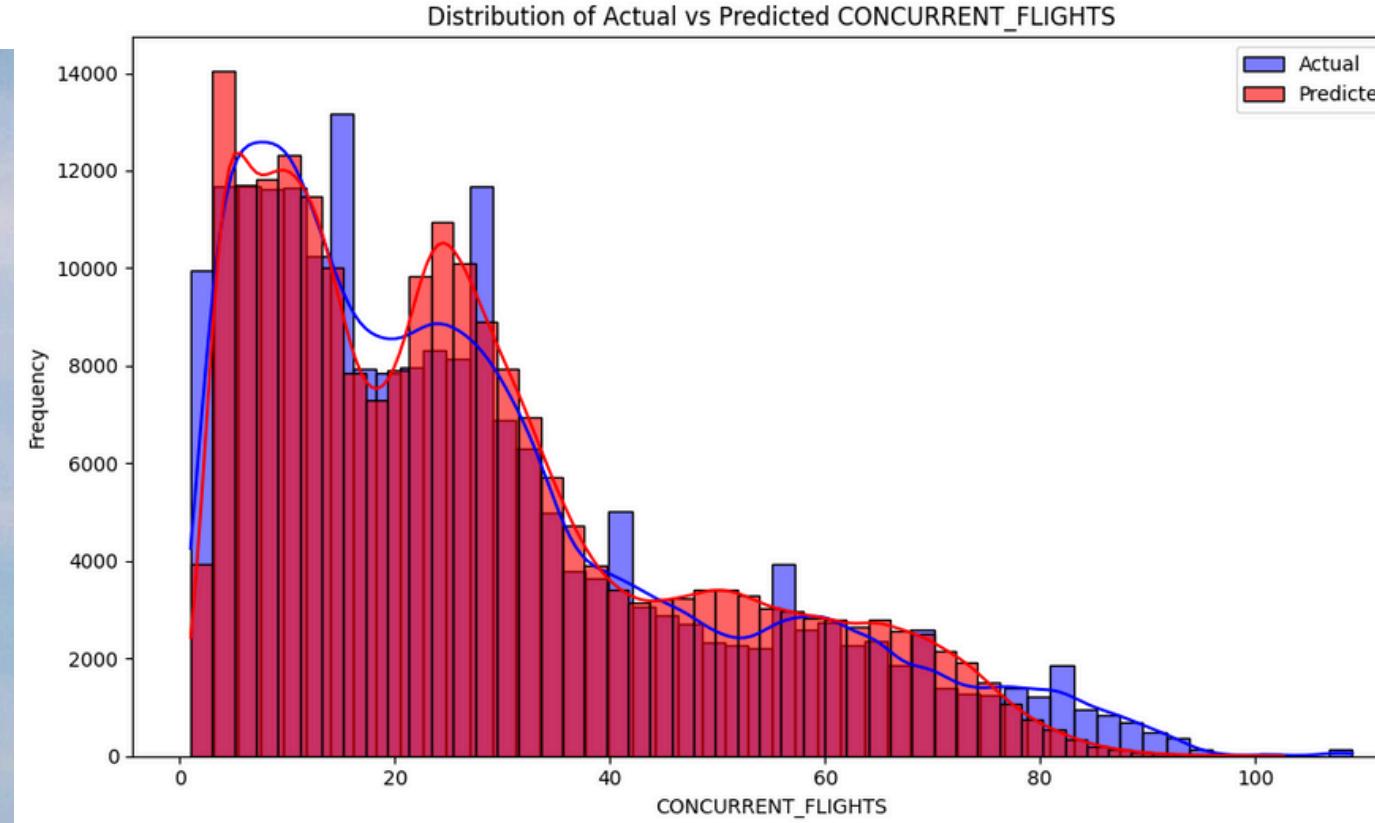
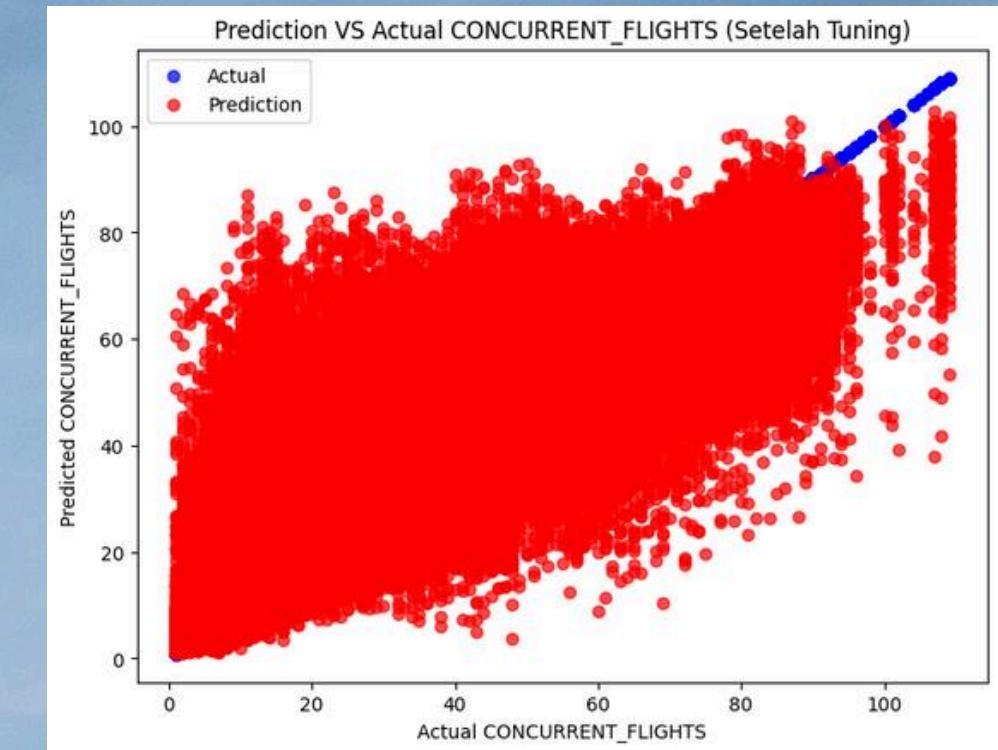
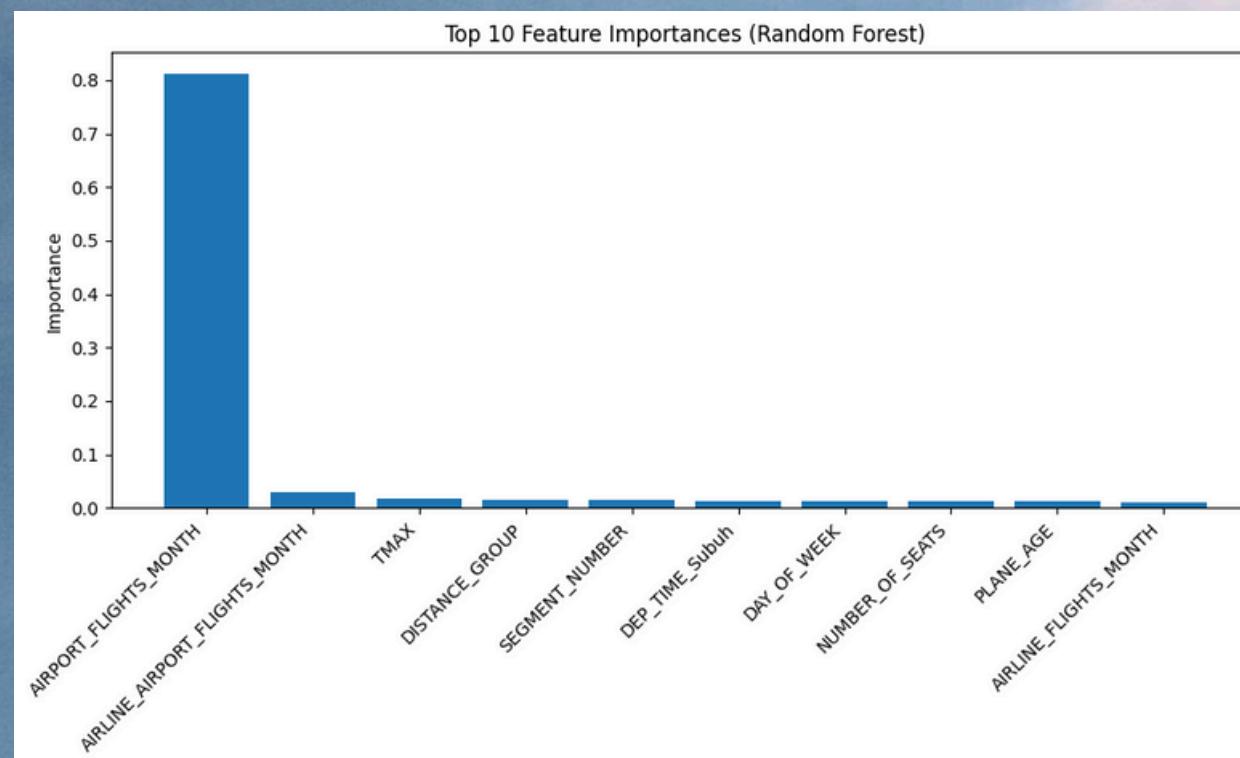
```
param_dist = {  
    'n_estimators': [100, 300, 500],  
    'max_depth': [None, 20, 30, 40],  
    'min_samples_split': [2, 5, 10],  
    'min_samples_leaf': [1, 2, 4, 8],  
    'max_features': ['sqrt', 'log2'],  
    'bootstrap': [True, False]  
}
```

```
r2_train = best_model.score(X_train, y_train)  
r2_test = best_model.score(X_test, y_test)  
  
print(f"Akurasi model pada data training: {r2_train * 100:.2f}%")  
print(f"Akurasi model pada data testing: {r2_test * 100:.2f}%")  
  
mae = mean_absolute_error(y_test, y_pred)  
rmse = math.sqrt(mean_squared_error(y_test, y_pred))  
  
print(f"Rata-rata kesalahan prediksi (MAE): {mae:.2f}")  
print(f"Rata-rata kesalahan terbesar (RMSE): {rmse:.2f}")
```

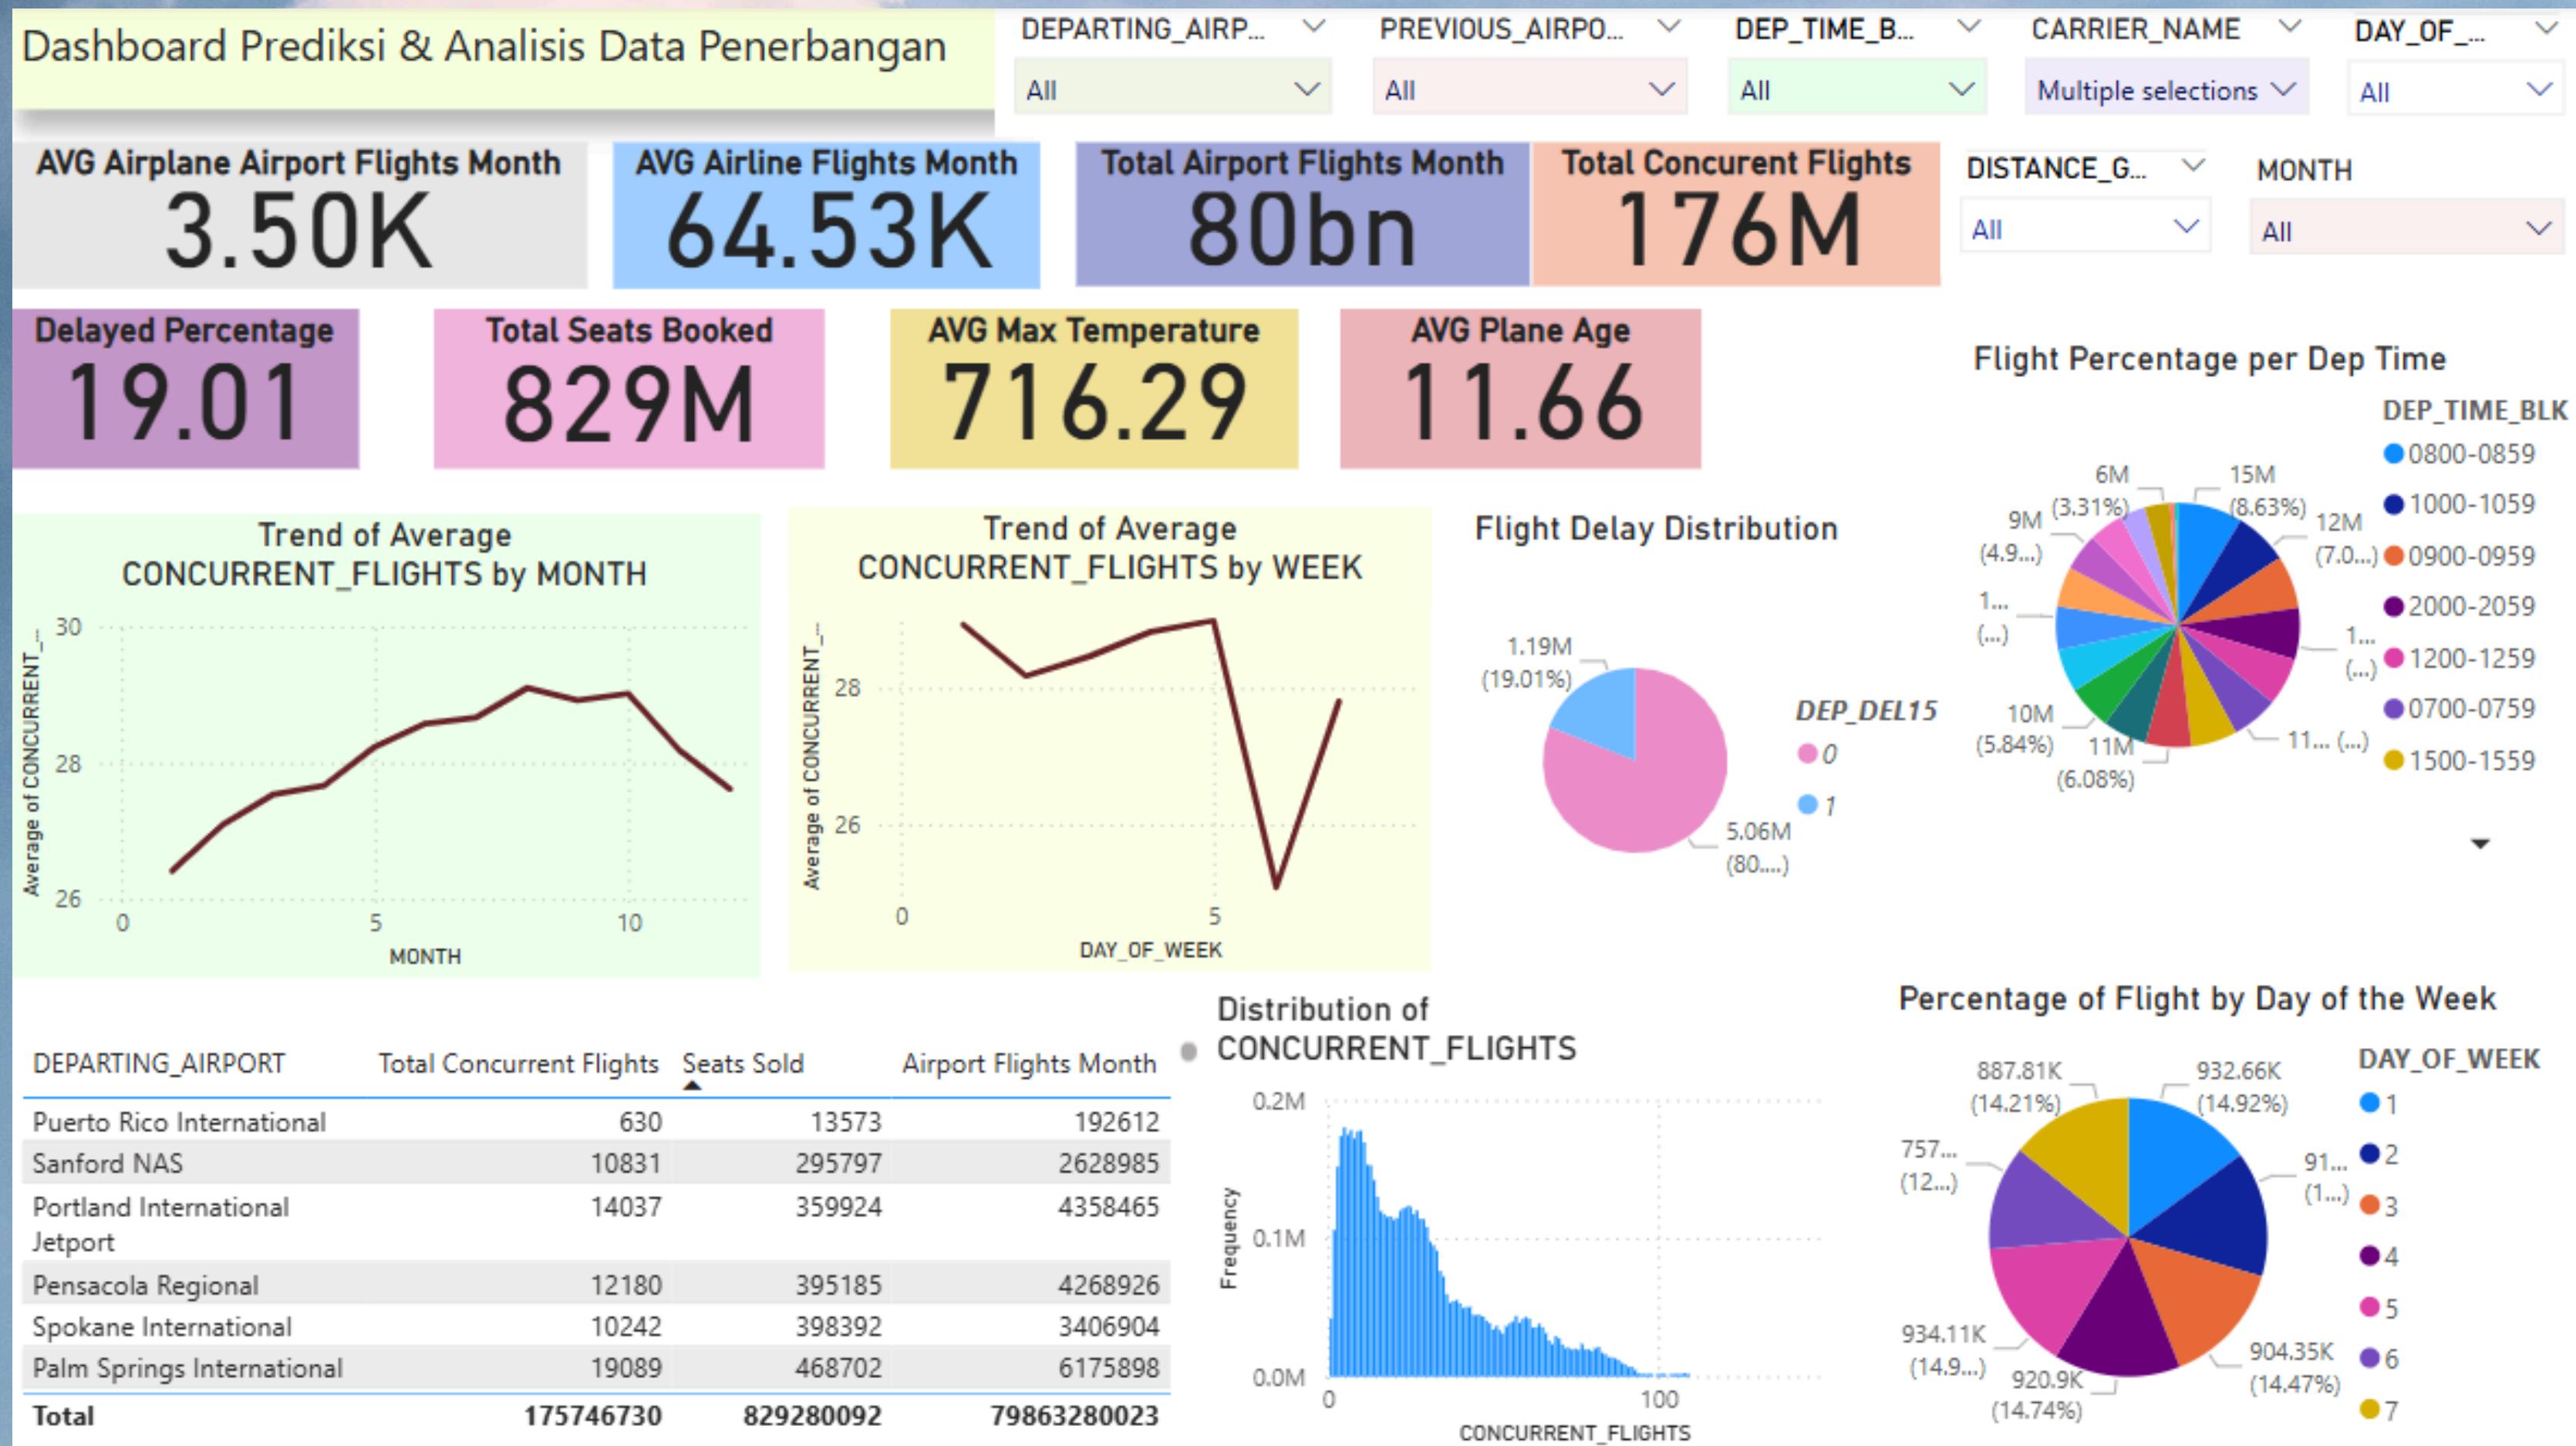
Akurasi model pada data training: 91.24%
Akurasi model pada data testing: 86.28%
Rata-rata kesalahan prediksi (MAE): 4.91
Rata-rata kesalahan terbesar (RMSE): 7.98

TRAINING DAN TESTING

Model di tuning menggunakan Random forest



DASHBORD INTERAKTIF INSIGHT BISNIS - POWERBI



KESIMPULAN

Analisis data ini berhasil membangun model prediksi jumlah penerbangan bersamaan (concurrent flights) menggunakan dataset besar (6 juta row) yang telah dibersihkan dan diproses, termasuk menghapus kolom tidak relevan, penanganan missing values, dan kategorisasi waktu keberangkatan. Dua algoritma yang digunakan adalah Random Forest dan XGBoost, dengan hasil akhir yang seimbang Random Forest mencapai akurasi testing 86.3% dan XGBoost 86.7% setelah hyperparameter tuning.

Kedua model menunjukkan performa yang baik, namun XGBoost lebih unggul karena fleksibilitas dan kemampuan regulasinya menjadikannya pilihan yang tepat untuk kasus prediksi berskala besar seperti ini. Model ini dapat dikembangkan lebih lanjut untuk mendukung pengambilan keputusan dalam pengelolaan lalu lintas udara.

DOKUMENTASI

Link Google drive Dokumentasi:

<https://drive.google.com/drive/folders/1aasLtL91DVTQG4ZR6IDApnQjpN63xhyc?usp=sharing>



Q&A



TERIMA
KASIH